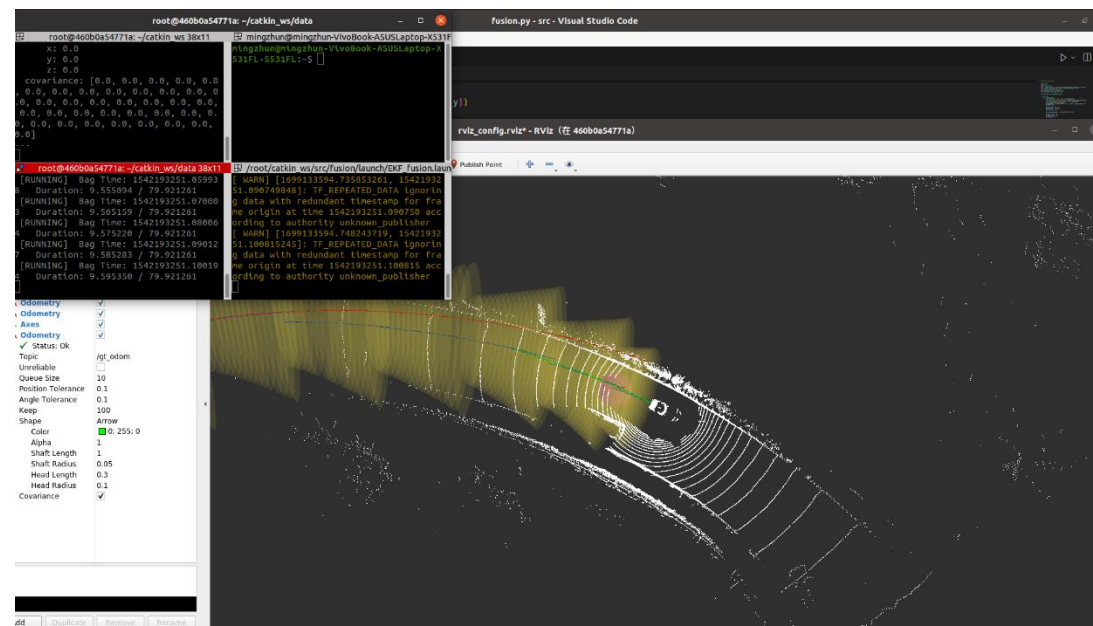
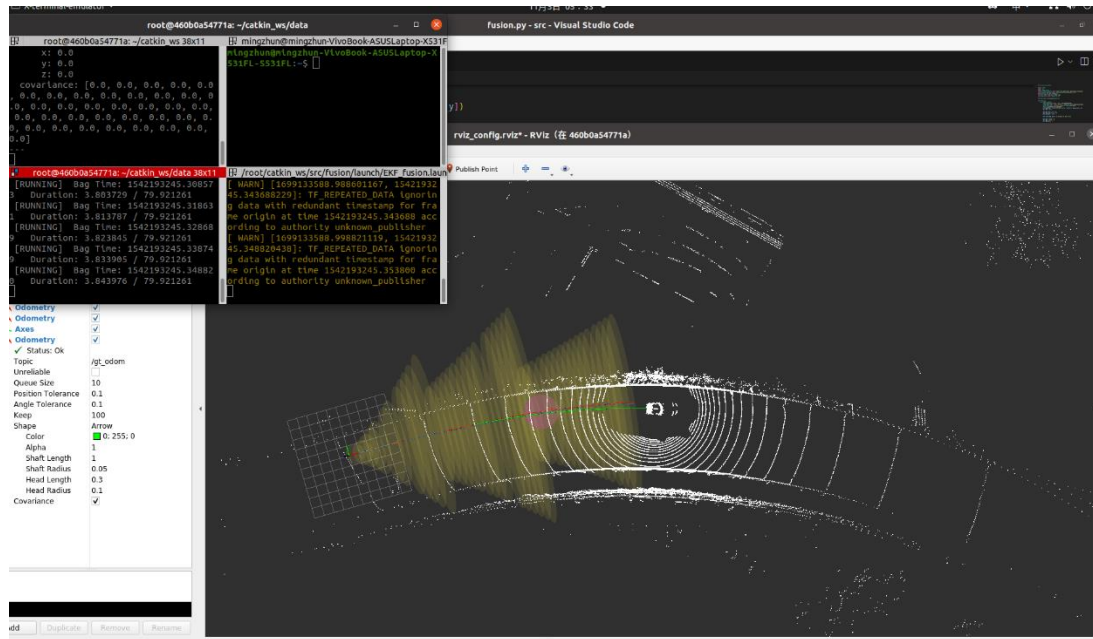
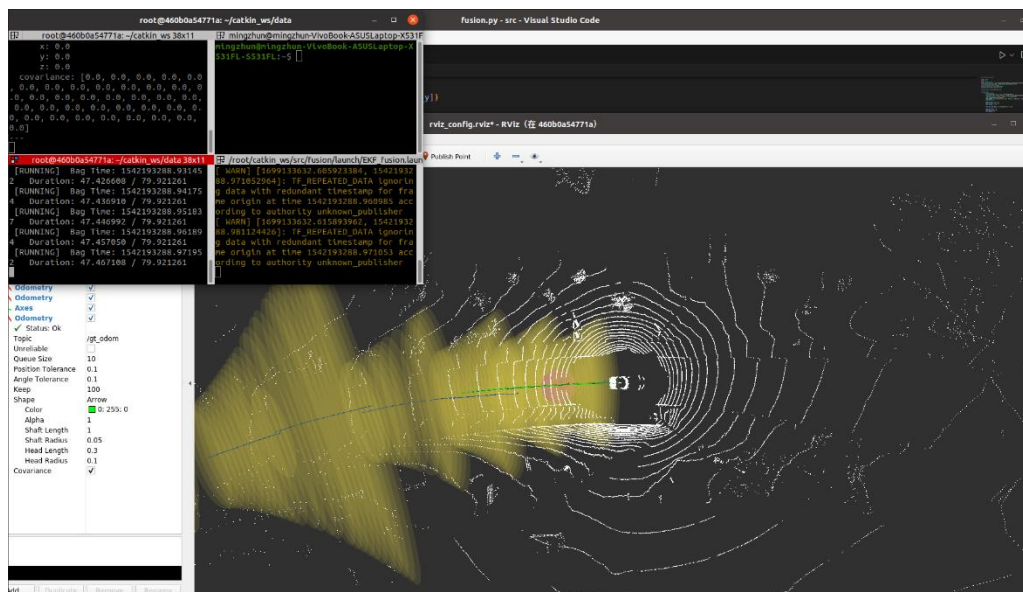
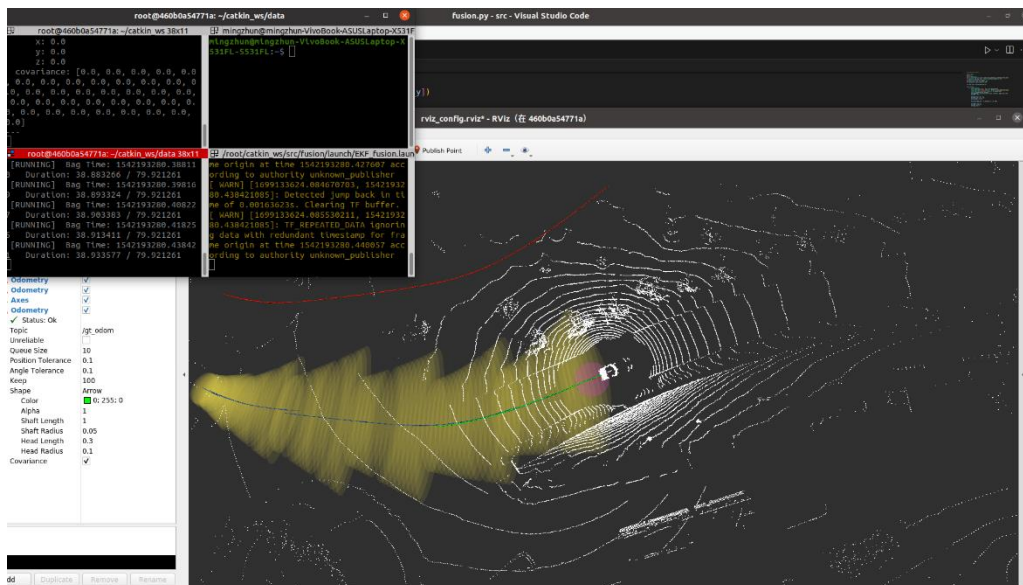
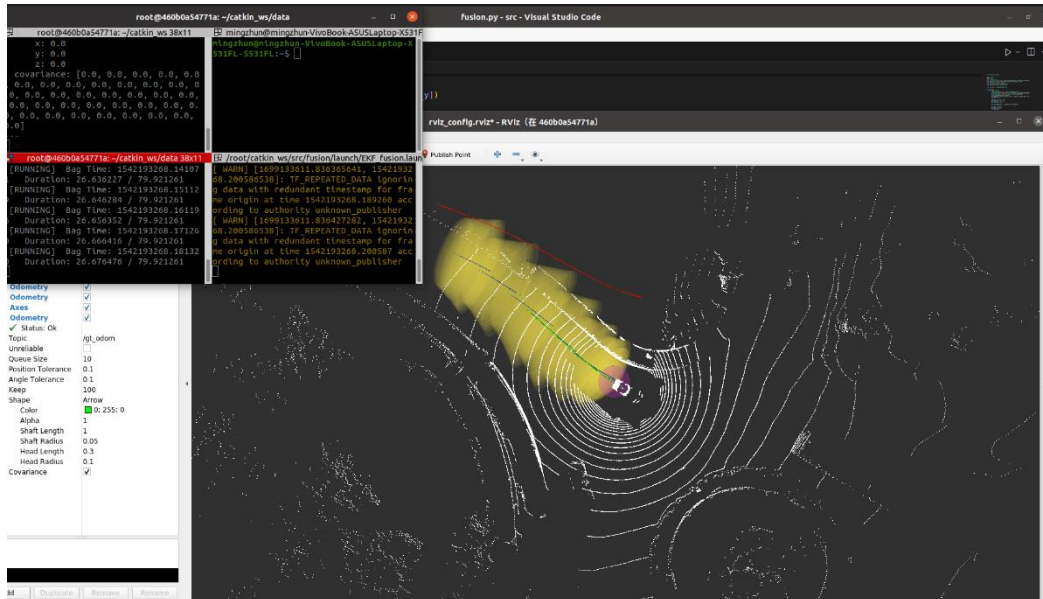


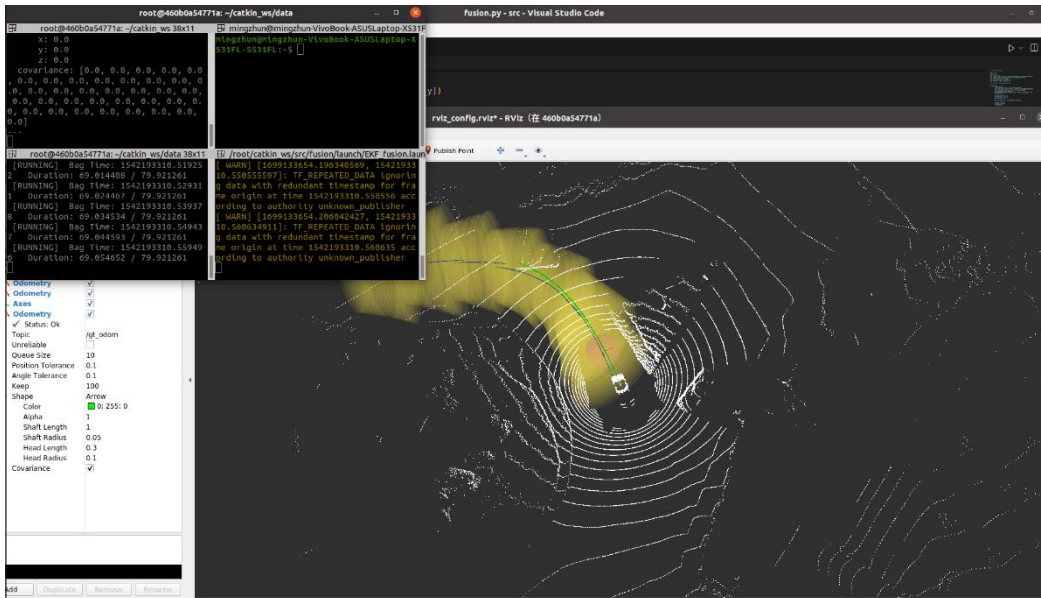
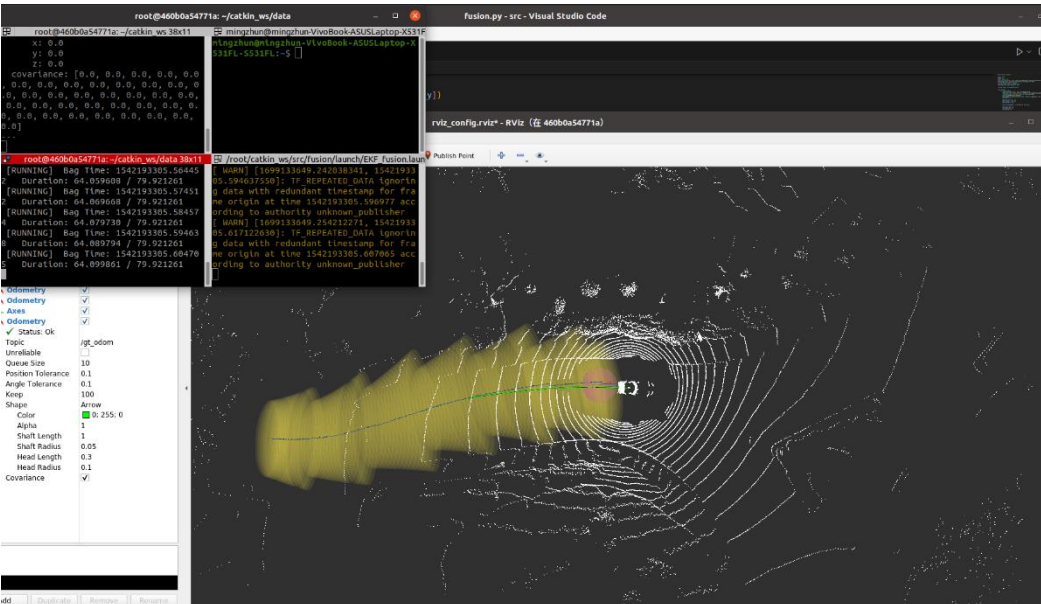
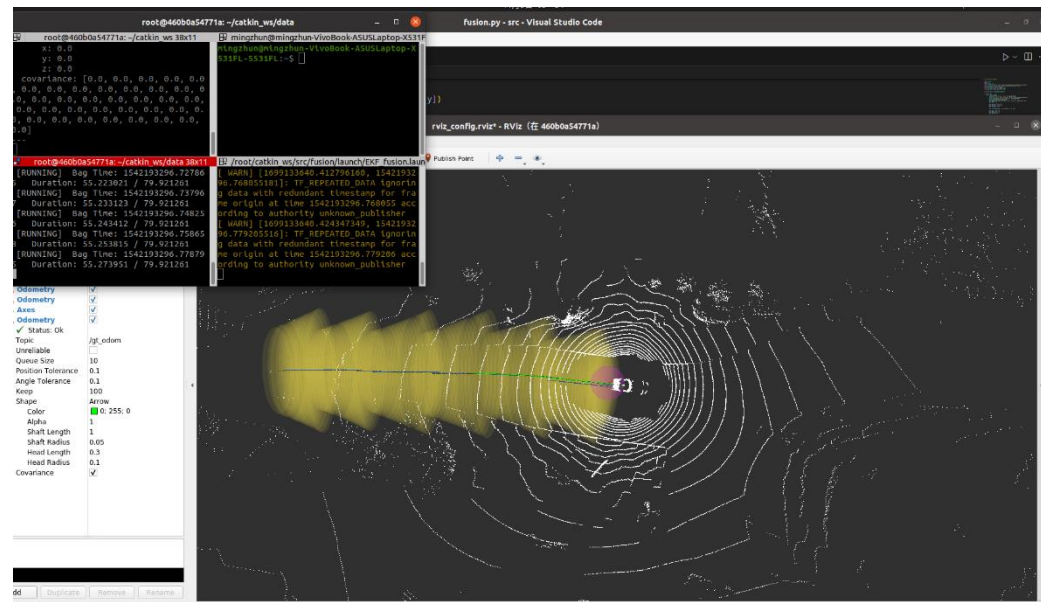
SDC Homework 4 - Application of EKF

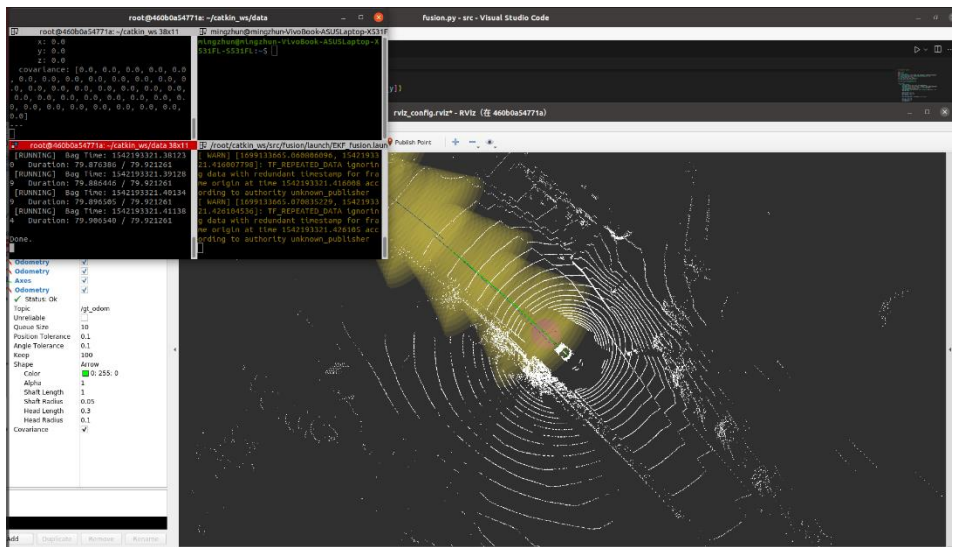
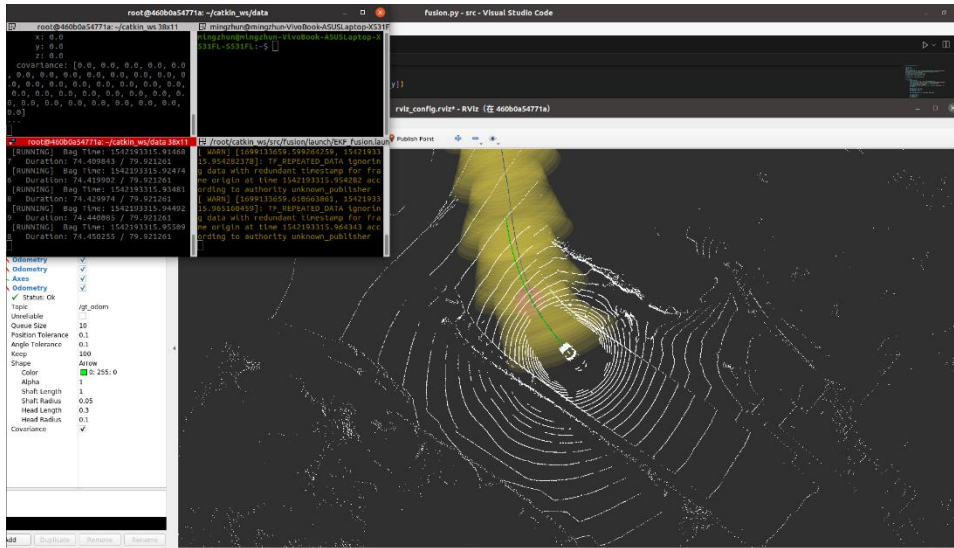
312512005 黃名諄

1. Screenshot of running program:










2. Result.png:



3. Discussion:

1. How do you design the EKF (motion model, observation matrix, states, etc.)?

- States:


只靠 radar odometry and GPS 難以取得速度資訊，因此 EKF 內我使用 only pose : x, y, yaw 當作 state 去預測更新

```
# etc...  
self.pose = np.array([x, y, yaw])
```

- Motion model:

在使用 EKF 時需要找到 nonlinear 方程，使用 radar odometry data 處理後當 control input 至 EKF Motion model 內，我的設計概念是藉由上一時刻($t-1$)在 world frame 下的 pose，預測當前時刻(t)在 world frame 下的 pose，而 control input 則是相對於上一時刻($t-1$)之 car local frame 下當前時刻(t)之 pose 位置，也就是改變量在上一時刻($t-1$)之 car local frame 下之表示，具體概念細節如下：

考慮俯視下，= 2D 平面



α_{t-1} : $t-1$ 時刻, local frame yaw

α_t : t 時刻, local frame yaw

ΔV : 表 local frame $t-1$ 原點相對 local frame t 原點之向量

P_t^w : local frame t 之原點在 world frame 下之表示

P_{t-1}^w : local frame $t-1$ 之原點在 world frame 下之表示

* goal: find transformation of P_w^{t-1} to P_w^t

由向量加法可知, $P_t^w = P_{t-1}^w + \Delta V^w$

ΔV^w 表向量 ΔV 在 world frame 下之表示

其中, 選擇 ΔV^w 可當做兩筆 odometry data 之變化量當作 control

丟入 EKF 之 prediction step 中

ΔV^{t-1} 表 ΔV 在 local frame $t-1$ 下之表示

EKF 中, P_{t-1}^w 是上一次儲存之 pose

, 藉 ΔV^{t-1} control to predict P_t^w (pose at t)


原先的 data 是 global frame 下, 可取得兩筆 data 在 world frame 下的改變量, 但我需要將此改變量轉成相對於上一時刻($t-1$)之 car local frame 下之表示再送入 EKF 中做預測, 具體細節如下推導:

* global change \rightarrow local change

將原得到的 data 相減, 表示的是相差之量在 world frame 下之表示

也就是 ΔV^w , 但需轉為相對於 $t-1$ 時 local frame 下的改變量再傳入 EKF

以下為原理推導:



α_{t-1} is yaw of local frame $t-1$ (已知)

將當前 odometry data 和 $t-1$ 時 odometry data 相減

\Rightarrow 得 $\Delta x^w, \Delta y^w$

$$\therefore \phi = \text{atan2}(\Delta y^w, \Delta x^w)$$

$$\therefore \theta = \phi - \alpha_{t-1}$$

$$\|\Delta V\| = \sqrt{(\Delta x^w)^2 + (\Delta y^w)^2}$$

$$\Rightarrow \begin{aligned} \Delta x^{t-1} &= \|\Delta V\| \times \cos \theta \\ \Delta y^{t-1} &= \|\Delta V\| \times \sin \theta \end{aligned}$$

$$\text{Fin } \Delta \gamma^w = \alpha_t - \alpha_{t-1}$$

因此, $u = \begin{bmatrix} \Delta x^{t+1} \\ \Delta y^{t+1} \\ \Delta yaw \end{bmatrix}$, 表示時刻 t 下之 pose 在 local frame $t-1$ 下之表示
當作 control 送入 EKF

```
# Calculate current pose in the last car local frame as control input of EKF
delta_x = odom_x - self.last_odom_pose[0]
delta_y = odom_y - self.last_odom_pose[1]
angle_world = atan2(delta_y, delta_x)
angle_local = angle_world - self.last_odom_pose[2]
delta_distance = sqrt(delta_x**2 + delta_y**2)

diff_x = delta_distance*cos(angle_local)
diff_y = delta_distance*sin(angle_local)
diff_yaw = odom_yaw - self.last_odom_pose[2]

self.last_odom_pose[0] = odom_x
self.last_odom_pose[1] = odom_y
self.last_odom_pose[2] = odom_yaw

#rospy.loginfo(odom_yaw)
control = np.array([diff_x, diff_y, diff_yaw])#???
```

接著要找 EKF 內 Motion model 的非線性轉換關係並找到其 Jacobian, 其實也只是配合座標轉換的向量加法關係, 詳細推導如

* EKF's motion model

EKF 之 state X 設為 pose, $np.array([x, y, yaw])$

如一開始之目標, 將 $P_t^w = P_{t-1}^w + \Delta V^w$

$$X_t = \begin{bmatrix} x_t \\ y_t \\ yaw_t \end{bmatrix}, \quad X_{t-1} = \begin{bmatrix} x_{t-1} \\ y_{t-1} \\ yaw_{t-1} \end{bmatrix}, \quad P_t^w = \begin{bmatrix} x_t \\ y_t \end{bmatrix}, \quad P_{t-1}^w = \begin{bmatrix} x_{t-1} \\ y_{t-1} \end{bmatrix}$$

$$\text{control: } u = \begin{bmatrix} \Delta x^{t+1} \\ \Delta y^{t+1} \\ \Delta yaw \end{bmatrix} \quad \text{其中 } \Delta V^{t+1} = \begin{bmatrix} \Delta x^{t+1} \\ \Delta y^{t+1} \end{bmatrix}, \quad \text{表 } t \text{ 時刻下 } x_t \text{ 和 } y_t \text{ 在 local frame } t-1 \text{ 下之表示}$$

已知 car local frame 和 world frame 是旋轉 + 平移關係

⇒ 兩座標間轉換可用 transform matrix T_{t-1}^w 表示

$$P_t^w = T_{t-1}^w \Delta V^{t+1}, \quad T_{t-1}^w = \begin{bmatrix} R_{t-1}^w & P_{t-1}^w \\ 0^T & 1 \end{bmatrix}$$

$\alpha = yaw_{t-1}$

$$\Rightarrow \begin{bmatrix} x_t \\ y_t \\ 1 \end{bmatrix} = \begin{bmatrix} \cos \alpha & -\sin \alpha & x_{t-1} \\ \sin \alpha & \cos \alpha & y_{t-1} \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \Delta x^{t+1} \\ \Delta y^{t+1} \\ 1 \end{bmatrix}$$

$$\Rightarrow \begin{aligned} x_t &= x_{t-1} + \cos \alpha \Delta x^{t+1} - \sin \alpha \Delta y^{t+1} \rightarrow f_1 \\ y_t &= y_{t-1} + \sin \alpha \Delta x^{t+1} + \cos \alpha \Delta y^{t+1} \rightarrow f_2 \end{aligned}$$

$$\text{For yaw 部分: } yaw_t = yaw_{t-1} + \Delta yaw \rightarrow f_3$$

下:

則 motion model 可整理成:

$$\begin{bmatrix} x_t \\ y_t \\ y_{aw_t} \end{bmatrix} = \begin{bmatrix} x_{t-1} \\ y_{t-1} \\ y_{aw_{t-1}} \end{bmatrix} + \begin{bmatrix} \cos \alpha & -\sin \alpha & 0 \\ \sin \alpha & \cos \alpha & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \Delta x^{t-1} \\ \Delta y^{t-1} \\ \Delta y_{aw} \end{bmatrix}$$

ll
u

此即我們的 motion model

接著需要 Jacobian matrix to predict state covariance matrix
↓
存在 self.A
self.S

$$\begin{aligned} \text{Jacobian matrix} &= \begin{bmatrix} \frac{\partial f_1}{\partial x_{t-1}} & \frac{\partial f_1}{\partial y_{t-1}} & \frac{\partial f_1}{\partial \alpha} \\ \frac{\partial f_2}{\partial x_{t-1}} & \frac{\partial f_2}{\partial y_{t-1}} & \frac{\partial f_2}{\partial \alpha} \\ \frac{\partial f_3}{\partial x_{t-1}} & \frac{\partial f_3}{\partial y_{t-1}} & \frac{\partial f_3}{\partial \alpha} \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0 & (-\sin \alpha) \Delta x^{t-1} - (\cos \alpha) \Delta y^{t-1} \\ 0 & 1 & (\cos \alpha) \Delta x^{t-1} - (\sin \alpha) \Delta y^{t-1} \\ 0 & 0 & 1 \end{bmatrix} \end{aligned}$$

⇒ state covariance prediction:

$$\text{self.S} = (\text{self.A}) (\text{self.S}) (\text{self.A})^T + \text{self.R}$$

將上述 motion model 在 EKF code 中實現如下:

```
#use transition matrix of world and last car local frame to get the nonlinear motion model
self.u_transition_matrix = np.array([ [cos(self.pose[2]), -sin(self.pose[2]), 0],
                                       [sin(self.pose[2]), cos(self.pose[2]), 0],
                                       [0, 0, 1] ])

#A is Jacobian matrix here
self.A = np.array([ [1, 0, (-u[0]*sin(self.pose[2])-u[1]*cos(self.pose[2]))],
                    [0, 1, (u[0]*cos(self.pose[2])-u[1]*sin(self.pose[2]))],
                    [0, 0, 1] ])

self.pose = self.pose + np.dot(self.u_transition_matrix, u)
self.S = np.dot(np.dot(self.A, self.S), self.A.T) + self.R
```

- observation matrix

對於 observation model, 我還是使用 hw3 中的線性關係

$$\begin{bmatrix} z_x \\ z_y \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} x \\ y \\ y_{aw} \end{bmatrix} + \delta_t$$


```
def update(self, z):
    # Base on the Kalman Filter design in Assignment 3
    # Implement a linear or nonlinear observation matrix for the measurement input
    # Calculate Jacobian matrix of the matrix as self.C
    |
    #use linear observation model as hw3
    K = np.dot(np.dot(self.S, self.C.T), np.linalg.inv((np.dot(np.dot(self.C, self.S), self.C.T) + self.Q)))
    self.pose = self.pose + np.dot(K, (z - np.dot(self.C, self.pose)))
    self.S = np.dot((np.identity(3)-np.dot(K, self.C)), self.S)
    return self.pose, self.S

# Observation matrix
self.C = np.array([[1,0,0],[0,1,0]])
#self.C = np.identity(3)
```

使用的觀測 data 是 gps，但其只有 x,y 沒有 yaw 的資訊，在這個 update 步驟中我直接使用 gps 的 x,y 觀測而沒有使用到估算的 yaw，這是因為其實我有嘗試過使用兩筆 data 來計算 $\text{atan2}(dy1, dx1)$

```
# use 2 gps data to find a approximate yaw
dx1 = gps_x- self.gps_x_last
dy1 = gps_y - self.gps_y_last
gps_distance = sqrt(dx1**2+dy1**2)

# if car stop whin a range, then don't change the approximate yaw
if gps_distance > 1:
    self.gps_yaw = atan2(dy1,dx1)
measurement = np.array([gps_x, gps_y, self.gps_yaw])
self.gps_x_last = gps_x
self.gps_y_last = gps_y
...
```

當作粗略估計的測量 yaw 值丟入 EKF 做 update，但並沒有更好的效果，原因我認為是其不是真的觀測數據，而是近似的 yaw，本身可靠度就不高，並不能給予更好的修正，結果比較如下方：




figure 1 demo with use gps approximate yaw




figure 2 result with use gps approximate yaw




figure 3 result use gps directly

因此我最後才使用如 hw3 之設計來直接使用 gps 的 x,y 觀測 data。

2. What is the covariance matrix of GPS, radar odometry and what does it mean?

covariance matrix 表示的是 sensor data 的 uncertainty，越大表示不確定性越大，而 EKF 結果會偏向於不確定性小的 data。兩 sensor 之 data 中都有包含其 covariance 資訊，但我在實作中有發現一些問題，對其做了一些調整來使結果更好，會在以下詳細討論

- modify the covariance matrix:

我有將兩 sensor 各自的 data 調出來看，可發現 radar odometry covariance 大概在 $10^{-5} \sim 10^{-7}$ ，非常的小，但 gps covariance 在 3，兩 sensor covariance 比例相差很大，但實際看起來 gps 應該要準一些，所以修改兩者 covariance，改變兩者 uncertainty 比例可得不同效果

radar odometry data:

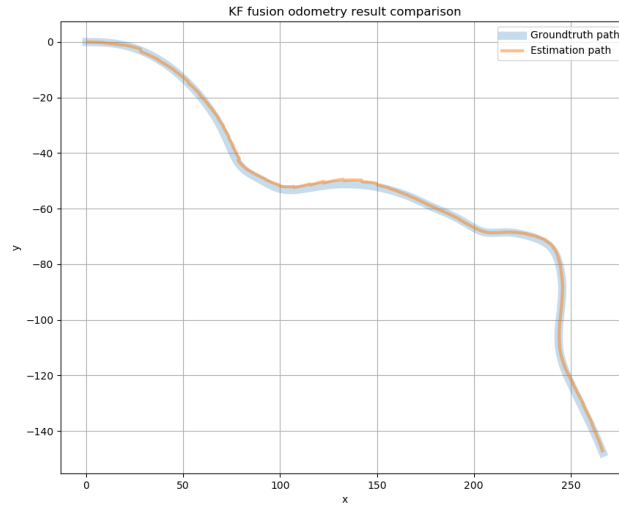
[illegible]

gps data:


[illegible]

因此我對兩者分別乘上不同的倍率比較結果，使用原始 data 的 covariance 結果不是最好的，最後試出來 radar odometry covariance 乘 1000 和 gps covariance 乘 10 會有最好的定位效果，幾個組合結果比較如下：

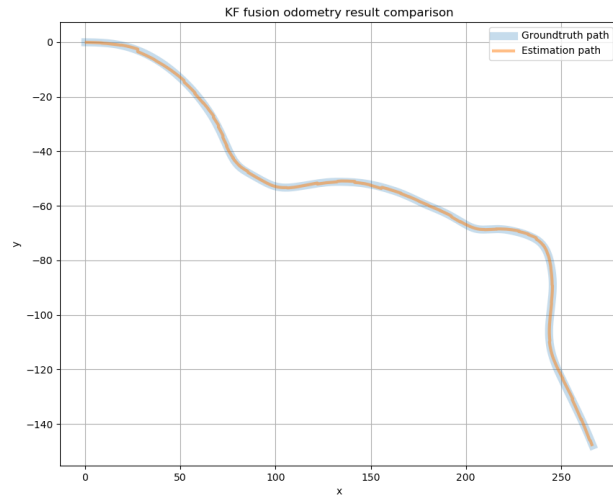
I. use original covariance:



II. use radar odometry covariance*1000 with original gps covariance



III. use radar odometry covariance*1000 with gps covariance*10



因此最後使用的 covariance matrix 如下：

- radar odometry covariance matrix (use in motion model)

```
else:
    # Update error covariance
    self.EKF.R = np.array([[odom_covariance[0,0],odom_covariance[0,1],odom_covariance[0,5]],
                           [odom_covariance[1,0],odom_covariance[1,1],odom_covariance[1,5]],
                           [odom_covariance[5,0],odom_covariance[5,0],odom_covariance[5,5]]
                           ])*1000 #???
```

- gps covariance matrix (use in observation model)

```
else:
    # Update error covariance
    self.EKF.Q = np.array([[gps_covariance[0][0], gps_covariance[0][1]],
                           [gps_covariance[1][0], gps_covariance[1][1]]
                           ]
                           )*10 #???
    self.EKF.update(z = measurement)
```